

Deep Learning

Episodio 4: La Operación de Convolución

Fernando Gama

Escuela de Graduados en Ingeniería Informática y Sistemas, Facultad de Ingeniería, UBA

28 de Julio de 2022

- ▶ Minimizar el riesgo empírico usando gradiente descendente
 - ⇒ Implica que la función es **derivable** ⇒ **Costo vs. Pérdida**
- ▶ No necesariamente necesitamos encontrar el mínimo, sino bajar el costo
- ▶ Muestras de **validación** ⇒ Sirven para **observar el overfitting**
- ▶ **Regularización** ⇒ Técnicas para **mejorar la generalización** del modelo
 - ⇒ Penalidades ⇒ Agregan un término a la función de pérdida
 - ⇒ Parada anticipada ⇒ Fácil implementación, requiere muestras de validación
 - ⇒ Dropout ⇒ Apagar neuronas de manera aleatoria ⇒ Evitar memorización


Señales y Sistemas

Convolución

Respuesta en Frecuencia


Convoluciones en Imágenes

- ▶ Los **datos** los consideramos vectores $\mathbf{x} \in \mathbb{R}^N$
 - ⇒ Asumimos que los **elementos del vector no guardan relación entre sí**




- ▶ ¿Qué pasa si el vector representa algún otro tipo de dato que sí guarda relación entre los elementos?
 - ⇒ ¿Qué hacemos?
 - ⇒ ¿Podemos **usar esa relación para mejorar** nuestros algoritmos de aprendizaje?

- ▶ Un tipo de datos que son muy comunes son los datos que **dependen del tiempo**
- ▶ Sea $\mathcal{N} = \{0, \dots, N - 1\}$ un conjunto de N índices temporales discretos
- ▶ Definimos una **señal** como $x : \mathcal{N} \rightarrow \mathbb{R} \Rightarrow$ **A cada índice temporal le asignamos un escalar**




- Podemos describir la **señal** como un **vector N -dimensional**



- El primer elemento del vector corresponde al valor de la señal en tiempo 0
⇒ El segundo elemento al tiempo 1, y así sucesivamente
- Nosotros sabemos que los elementos del vector están relacionados
⇒ Pero **esta relación no aparece naturalmente en el vector** ⇒ ¿Cómo lo recuperamos?

- ▶ Lo que queremos hacer es **transformar los datos** de alguna manera apropiada
 - ⇒ Si los datos tienen alguna estructura particular ⇒ **Explotar la estructura en la transformación**
- ▶ **Sistema** ⇒ Una función que **toma una señal y devuelve una señal**
- ▶ Si definimos \mathbb{X}_N como el espacio de señales $\mathbb{X}_N = \{x : \mathcal{N} \rightarrow \mathbb{R}\}$
 - ⇒ Un sistema es una función $H : \mathbb{X}_N \rightarrow \mathbb{X}_N$
- ▶ El procesamiento de la señal a través del **sistema** H tiene que **explotar la estructura de los datos**
 - ⇒ A través del uso de sistemas pertinentes recuperamos la noción de tiempo



- ▶ Sistema lineal: $y(n) = H(x) = ax(n)$ para algún $a \in \mathbb{R}$
⇒ Como vectores: $\mathbf{x} = [x_1, x_2, x_3, x_4] \mapsto \mathbf{y} = [ax_1, ax_2, ax_3, ax_4]$
- ▶ Sistema no-lineal: $y(n) = H(x) = (x(n))^2$ ⇒ Aplicamos la función a cada instante de tiempo
⇒ Como vectores: $\mathbf{x} = [x_1, x_2, x_3, x_4] \mapsto \mathbf{y} = [x_1^2, x_2^2, x_3^2, x_4^2]$
- ▶ Estos son ejemplos de **sistemas sin memoria** ⇒ La noción de tiempo no aparece de manera explícita

- ▶ Sistema con demora unitaria: $y(n) = H(x) = x(n-1)$
⇒ Como vectores: $\mathbf{x} = [x_1, x_2, x_3, x_4] \mapsto [?, x_1, x_2, x_3]$
- ▶ Promediador móvil: $y(n) = H(x) = x(n) + x(n-1)$
⇒ Como vectores: $\mathbf{x} = [x_1, x_2, x_3, x_4] \mapsto [x_1 + ?, x_2 + x_1, x_3 + x_2, x_4 + x_3]$
- ▶ ¿Qué se hace en estos **casos donde necesito datos temporales que no tengo?**
⇒ Hay muchas alternativas: asumir que son cero (*zero-padding*), reducir el tamaño de salida, ...

Señales y Sistemas

Convolución

Respuesta en Frecuencia

Convoluciones en Imágenes

- **Sistema Lineal** \Rightarrow Combinación lineal a la entrada produce combinación lineal a la salida

$$H(a_1x_1 + a_2x_2 + \cdots + a_Kx_K) = a_1H(x_1) + a_2H(x_2) + \cdots + a_KH(x_K)$$

- Operación de demora o desplazamiento $y(n) = D_k(x) = y(n - k)$

- **Sistema invariante en el tiempo**


$$H(D_k(x)) = D_k(H(x))$$

\Rightarrow Desplazar la señal de entrada genera un desplazamiento igual en la salida

Si $y(n) = H(x)$ es la salida, entonces $H(x(n-k)) = H(D_k(x)) = D_k(H(x)) = D_k(y) = y(n-k)$

- Definimos la señal conocida como *delta* (también se conoce como **impulso**)


$$\delta(n) = \begin{cases} 1 & \text{si } n = 0 \\ 0 & \text{en otro caso} \end{cases}$$




- Como vector, se puede escribir como $\delta = [1, 0, \dots, 0] \in \mathbb{R}^N$

- Explotando las nociones de **linealidad** y **desplazamiento**, podemos descomponer cualquier señal

$$x = \sum_{n=0}^{N-1} x_n D_n(\delta) = x_0 D_0(\delta) + x_1 D_1(\delta) + \cdots + x_{N-1} D_{n-1}(\delta)$$



=



- Descomponer una señal como una combinación lineal de deltas desplazadas es obvio en vectores

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}$$

$$= \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = x_1 \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix} + x_2 \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix} + x_3 \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix} + x_4 \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

- ▶ Usamos la decomposición para **calcular la salida de un sistema LTI** (lineal, invariante en el tiempo)

$$H(x) = H\left(\sum_{n=0}^{N-1} x_n D_n(\delta)\right) = \sum_{n=0}^{N-1} x_n D_n(H(\delta))$$

- ▶ $H(\delta)$ es aplicar el sistema LTI H a la señal δ

⇒ Se conoce como **respuesta impulsiva del filtro** ⇒ También es una señal **$h = H(\delta)$**

$$H(x) = \sum_{n=0}^{N-1} x_n D_n(h)$$

- ▶ La salida del filtro

⇒ Se calcula como una **combinación lineal de versiones desplazadas de la respuesta impulsiva**

⇒ Los **coeficientes** de la combinación son los valores de la **señal de entrada**

- La **respuesta impulsiva** del filtro también **es una señal h**

$$H(x) = \sum_{n=0}^{N-1} x_n D_n(h)$$

⇒ Esta señal caracteriza por completo al filtro

⇒ **Conociendo h podemos calcular la salida para cualquier señal de entrada**

- Podemos pensar la salida del filtro como **poner h a la entrada** de **un filtro X** con **respuesta impulsiva x**

$$X(h) = \sum_{n=0}^{N-1} h_n D_n(x) = \sum_{n=0}^{N-1} x_n D_n(h) = H(x)$$

⇒ La operación para calcular la salida del filtro es **conmutativa**

⇒ La respuesta impulsiva h puede tener $K \ll N$ coeficientes ⇒ Se puede diseñar (o aprender)

‘

- ▶ La operación para calcular la salida del filtro se conoce como **convolución**

$$\mathbf{h} * \mathbf{x} = \sum_{k=0}^{K-1} h_k \mathbf{D}_k(\mathbf{x})$$

donde $\mathbf{h} = \sum_{k=0}^{K-1} h_k \mathbf{D}_k(\delta)$ es la respuesta impulsiva del filtro

- ▶ El **resultado** de la operación de convolución $\mathbb{X}_N \times \mathbb{X}_K \rightarrow \mathbb{X}_M$ **es otra señal** $\Rightarrow \mathbf{y} = \mathbf{h} * \mathbf{x}$
 \Rightarrow El elemento n de la señal de salida se puede calcular explícitamente como




$$\mathbf{y}(n) = (\mathbf{h} * \mathbf{x})(n) = \sum_{k=0}^{K-1} \mathbf{h}(k) \mathbf{x}(n - k)$$

- ▶ Esta es la definición tradicional de convolución para señales en 1 dimensión
- ▶ Para otras señales el operador desplazamiento \mathbf{D}_n puede tener otras formas



- ▶ La operación de convolución es: combinación lineal, desplazar, combinación lineal, desplazar, ...
- ▶ Tenemos dos señales: una es el filtro h y la otra son los datos x






- ▶ La convolución implica una combinación lineal y un desplazamiento



- ▶ La convolución es **conmutativa** $\Rightarrow h * x = x * h \Rightarrow$ La noción de filtro y señal es intercambiable
 \Rightarrow Conceptualmente, filtro \neq señal (y porque hay otros dominios donde no conmutan)
- ▶ La convolución es **lineal** $\Rightarrow h * (a_1 x_1 + a_2 x_2) = a_1 (h * x_1) + a_2 (h * x_2)$
- ▶ La convolución es **asociativa** $\Rightarrow h_1 * (h_2 * x) = (h_1 * h_2) * x$





Sistemas en paralelo



Sistemas en cascada

- ▶ Tenemos un filtro h con K coeficientes, tenemos una señal x con N valores
⇒ La convolución está bien definida en $N - K + 1$ valores



- ▶ No se rellena con ceros ⇒ Tener cuidado de señales cada vez más pequeñas
- ▶ Se rellena con ceros de tal forma que la salida tenga tamaño N , igual que la entrada
⇒ Los valores en los bordes tienen menos influencia en la salida ⇒ Efectos de borde

Señales y Sistemas

Convolución

Respuesta en Frecuencia

Convoluciones en Imágenes

- ▶ Consideremos la señal **exponencial compleja** $x_t(n) = e^{j(2\pi t/N)n}$ con $t \in \{0, 1, \dots, N-1\}$
- ▶ Consideremos un **sistema LTI** con respuesta impulsiva $\mathbf{h} = [h_0, \dots, h_{K-1}] \in \mathbb{R}^K$
- ▶ La salida se calcula mediante la operación de **convolución**

$$H(x(n)) = (\mathbf{h} * x_t)(n) = \sum_{k=0}^{K-1} h_k e^{j \frac{2\pi t}{N} (n-k)} = \left(\sum_{k=0}^{K-1} h_k e^{-j \frac{2\pi t}{N} k} \right) e^{j \frac{2\pi t}{N} n} = \tilde{h}_t e^{j \frac{2\pi t}{N} n} = \tilde{h}_t x_t(n)$$

- ⇒ La **salida** del sistema es **igual a la entrada**, pero **reescalada** ⇒ $H(x_t(n)) = \tilde{h}_t x_t(n)$
- ⇒ Resulta que la exponencial compleja $x(n) = e^{j(2\pi t/N)n}$ es una **autofunción** del sistema LTI
- ▶ El **autovalor** \tilde{h}_t se conoce como la **respuesta en frecuencia** del filtro en la frecuencia t

$$\tilde{h}_t = \sum_{k=0}^{K-1} h_k e^{-j \frac{2\pi t}{N} k}$$

- La **respuesta en frecuencia** del filtro a frecuencia t viene dada por

$$\tilde{h}_t = \sum_{k=0}^{N-1} h_k e^{-j \frac{2\pi t}{N} k}$$

donde h_k son los valores de la **respuesta impulsiva** (que es una señal) y donde $h_k = 0$ para $k > K$

- Esta operación es un **producto interno** entre vectores $\Rightarrow \tilde{h}_t = \langle \mathbf{e}_t, \mathbf{h} \rangle = \mathbf{e}_t^H \mathbf{h} \in \mathbb{C}$ tal que

$$\tilde{h}_t = \mathbf{e}_t^H \mathbf{h} = \begin{bmatrix} e^{-j \frac{2\pi t}{N} 0} & e^{-j \frac{2\pi t}{N} 1} & \dots & e^{-j \frac{2\pi t}{N} (N-1)} \end{bmatrix} \begin{bmatrix} h_0 \\ h_1 \\ \vdots \\ h_{N-1} \end{bmatrix} = \sum_{k=0}^{N-1} h_k e^{-j \frac{2\pi t}{N} k}$$

- Dijimos que había $t \in \{0, 1, \dots, N-1\}$ **valores distintos de frecuencia**
 - \Rightarrow Cada uno se calcula como el **producto interno** $\tilde{h}_t = \mathbf{e}_t^H \mathbf{h}$ \Rightarrow El vector \mathbf{h} no cambia
 - \Rightarrow Se puede escribir como un producto de una **matriz con un vector** \Rightarrow Ponemos \mathbf{e}_t^H en las filas

$$\begin{bmatrix} \tilde{h}_0 \\ \tilde{h}_1 \\ \vdots \\ \tilde{h}_{N-1} \end{bmatrix} = \begin{bmatrix} e^{-j\frac{2\pi 0}{N} 0} & e^{-j\frac{2\pi 0}{N} 1} & \dots & e^{-j\frac{2\pi 0}{N} (N-1)} \\ e^{-j\frac{2\pi 1}{N} 0} & e^{-j\frac{2\pi 1}{N} 1} & \dots & e^{-j\frac{2\pi 1}{N} (N-1)} \\ \vdots & \vdots & \ddots & \vdots \\ e^{-j\frac{2\pi (N-1)}{N} 0} & e^{-j\frac{2\pi (N-1)}{N} 1} & \dots & e^{-j\frac{2\pi (N-1)}{N} (N-1)} \end{bmatrix} \begin{bmatrix} h_0 \\ h_1 \\ \vdots \\ h_{N-1} \end{bmatrix}$$

- Obtenemos la **respuesta en frecuencia del filtro** para todas las frecuencias

$$\tilde{\mathbf{h}} = \mathbf{E}^H \mathbf{h}$$

\Rightarrow Es una operación lineal, un producto de una matriz con un vector

- ▶ La **respuesta en frecuencia** se calcula como una **transformación lineal** de la **señal**

$$\tilde{\mathbf{h}} = \mathbf{E}^H \mathbf{h}$$

- ▶ La matriz \mathbf{E}^H es una matriz unitaria (ortogonal) \Rightarrow Su inversa es $(\mathbf{E}^H)^{-1} = \mathbf{E}$
 \Rightarrow Podemos escribir la **señal** como una **transformación lineal** de la **respuesta en frecuencia**

$$\mathbf{E} \tilde{\mathbf{h}} = \mathbf{h}$$

- ▶ La **señal** a cada instante $h(n)$ se puede escribir en una **descomposición** de **exponenciales complejas**


$$h(n) = \sum_{t=0}^{N-1} \tilde{h}_t e^{j \frac{2\pi t}{N} n}$$

\Rightarrow Los elementos de la combinación lineal son la respuesta en frecuencia


- Una exponencial compleja representa oscilaciones a frecuencia $2\pi t/N$

$$e^{j \frac{2\pi t}{N} n} = \cos\left(\frac{2\pi t}{N} n\right) + j \sin\left(\frac{2\pi t}{N} n\right)$$


- Para $t = 0$ tenemos una **señal constante** $\Rightarrow \cos((2\pi 0/N)n) = 1$ y $\sin((2\pi 0/N)n) = 0$ para todo n
- A medida que t aumenta, las oscilaciones son cada vez más rápidas
- Las oscilaciones más rápidas de todas se dan para $t = N/2$**
- Luego de $t = N/2$, **las oscilaciones vuelven a bajar** en frecuencia




$t = 0$



$t = N/6$



$t = N/2$









$t = 5N/6$

- Cada componente de la respuesta en frecuencia se calcula como el **producto interno**

$$\tilde{h}_t = \langle \mathbf{e}_t, \mathbf{h} \rangle = \mathbf{e}_t^H \mathbf{h}$$

⇒ El producto interno determina **qué tanto se parecen los vectores**

⇒ El producto $\mathbf{e}_t^H \mathbf{h}$ me dice **qué porción de la señal oscila a frecuencia t**



- Podemos escribir una señal como una descomposición de exponenciales complejas

$$h(n) = \sum_{t=0}^{N-1} \tilde{h}_t e^{j \frac{2\pi t}{N} n} \quad , \quad x(n) = \sum_{t=0}^{N-1} \tilde{x}_t e^{j \frac{2\pi t}{N} n}$$

- ¿Qué pasa con la **respuesta en frecuencia de la convolución**?

$$y(n) = (h * x)(n) = \sum_{t=0}^{N-1} \tilde{y}_t e^{j \frac{2\pi t}{N} n}$$

- ¿Cuál es la **relación** entre las respuestas en frecuencia \tilde{y}_t , \tilde{h}_t y \tilde{x}_t ?

- ▶ La convolución se calcula como $y(n) = \sum_{k=0}^{N-1} h(k)x(n-k)$
- ▶ Reemplazamos $h(n)$ y $x(n)$ por sus **descomposiciones en exponenciales complejas**

$$y(n) = \sum_{k=0}^{N-1} h(k)x(n-k) = \sum_{k=0}^{N-1} \left(\sum_{\tau=0}^{N-1} \tilde{h}_{\tau} e^{j \frac{2\pi \tau}{N} k} \right) \left(\sum_{t=0}^{N-1} \tilde{x}_t e^{j \frac{2\pi t}{N} (n-k)} \right)$$

- ▶ Distribuimos $\sum_{t=0}^{N-1} \sum_{\tau=0}^{N-1} \sum_{k=0}^{N-1} \tilde{h}_{\tau} \tilde{x}_t e^{j \frac{2\pi(\tau-t)}{N} k} e^{j \frac{2\pi t}{N} n} = \sum_{t=0}^{N-1} \tilde{x}_t e^{j \frac{2\pi t}{N} n} \sum_{\tau=0}^{N-1} \tilde{h}_{\tau} \sum_{k=0}^{N-1} e^{j \frac{2\pi(\tau-t)}{N} k}$
- ▶ Usamos la propiedad de que las **exponenciales complejas se cancelan a sí mismas**

$$\sum_{\tau=0}^{N-1} \tilde{h}_{\tau} \sum_{k=0}^{N-1} e^{j \frac{2\pi(\tau-t)}{N} k} = \begin{cases} N\tilde{h}_t & \text{si } \tau = t \\ 0 & \text{en otro caso} \end{cases}$$

$$\Rightarrow \text{Usando la suma geométrica: } \sum_{k=0}^{N-1} e^{-j \frac{2\pi(\tau-t)}{N} k} = \begin{cases} \frac{1-e^{j2\pi(t-\tau)}}{1-e^{j \frac{2\pi(t-\tau)}{N}}} = 0 & \text{si } t \neq \tau \\ \sum_{k=0}^{N-1} 1 = N & \text{si } t = \tau \end{cases}$$

- ▶ Entonces, sabiendo que
$$\sum_{\tau=0}^{N-1} \tilde{h}_{\tau} \sum_{k=0}^{N-1} e^{j \frac{2\pi(\tau-t)}{N} k} = \begin{cases} N \tilde{h}_t & \text{si } \tau = t \\ 0 & \text{en otro caso} \end{cases}$$
- ▶ Lo usamos en la expresión de la convolución

$$\sum_{t=0}^{N-1} \tilde{x}_t e^{j \frac{2\pi t}{N} n} \sum_{\tau=0}^{N-1} \tilde{h}_{\tau} \sum_{k=0}^{N-1} e^{j \frac{2\pi(\tau-t)}{N} k} = N \sum_{t=0}^{N-1} \tilde{x}_t \tilde{h}_t e^{j \frac{2\pi t}{N} n}$$

- ▶ Observamos que esto es una combinación lineal de exponenciales complejas
 - ⇒ Es la respuesta en frecuencia de $y(n)$
 - ⇒ La respuesta en frecuencia a frecuencia t viene dada por

$$\tilde{y}_t = \tilde{h}_t \tilde{x}_t$$

- ▶ La **respuesta en frecuencia de una convolución** es la **multiplicación de las respuestas en frecuencia**

Convolución en el tiempo \Leftrightarrow Multiplicación en frecuencia

- ▶ Una vez que tenemos \tilde{y}_t para todo t podemos calcular la señal de salida $\mathbf{y} = \mathbf{E}\tilde{\mathbf{y}}$
- ▶ Existen **algoritmos muy rápidos para calcular la respuesta en frecuencia** y su inversa
 - \Rightarrow Fast Fourier Transform (depende del valor de t) – **no usan una multiplicación de matrices**
- ▶ Muchas implementaciones de la convolución toman el filtro y la señal de entrada
 - \Rightarrow Calculan las respuestas en frecuencias y multiplican el resultado
 - \Rightarrow Calculan la inversa para obtener la señal de salida

Señales y Sistemas

Convolución

Respuesta en Frecuencia


Convoluciones en Imágenes

- ▶ La operación de **convolución** permite explotar la **estructura de los datos**
⇒ “La estructura de los datos” ⇒ **Valores contiguos** en el vector están relacionados
- ▶ Señales temporales: x_i está muy relacionado con x_{i+1} , pero no mucho con x_{i+K} para $K \gg 1$
⇒ **Noción de frecuencia**: Si los valores contiguos cambian mucho, alta frecuencia
⇒ Si los valores lejanos cambian mucho, no podemos decir demasiado
- ▶ Otro ejemplo son las imágenes: **los píxeles contiguos de la imagen están relacionados**
⇒ Ordenamiento de los píxeles, detección de bordes, etc.

- ▶ Sabemos cómo aplicar la **convolución a vectores** \Rightarrow Vectoricemos la imagen



- ▶ Ahora que tenemos el vector, consideremos un filtro y calculemos la convolución



- ▶ Relaciona valores contiguos en las columnas, pega un salto cuando una columna termina \Rightarrow **No sirve**

- ▶ Recordemos la definición general de convolución $\Rightarrow h * x = \sum_{k=0}^{K-1} h_k D_k(x)$
 \Rightarrow El problema es que la noción de desplazamiento $D_k(x) = x(n-k)$ no sirve
- ▶ Las imágenes se definen como $x : \mathcal{M} \times \mathcal{N} \rightarrow \mathbb{R}^3 \Rightarrow$ Una coordenada vertical y una horizontal $x(m, n)$
- ▶ Hay, entonces, dos dimensiones de desplazamiento $D_{p,q}(x) = x(m-p, n-q)$
- ▶ Los filtros también tienen dos coordenadas $\Rightarrow h(m, n)$ para avanzar en ambas direcciones
- ▶ La convolución en imágenes se define como

$$y(m, n) = \sum_{p=0}^K \sum_{q=0}^{K'} h(p, q) x(m-p, n-q)$$

- \Rightarrow La salida también es una imagen \Rightarrow Tiene dos dimensiones
- \Rightarrow El filtro no tiene por qué ser cuadrado (aunque generalmente lo es) ($K \ll M, K' \ll N$)

- ▶ La operación de convolución es: combinación lineal, desplazar, combinación lineal, desplazar, ...
- ▶ Tenemos dos señales: una es el filtro h y la otra son los datos x



h



x

- ▶ La convolución implica una combinación lineal y un desplazamiento



- ▶ La convolución en imágenes es una convolución
 - ⇒ Las propiedades que vimos para la convolución en una dimensión valen
 - ⇒ Linealidad, aditividad, rellenar con ceros, etc.
- ▶ También existe una respuesta en frecuencia para imágenes
 - ⇒ También hace el cálculo de la convolución más rápido

- ▶ A veces, los **datos tienen estructuras** que se pueden explotar para mejorar el algoritmo
⇒ Señales en el tiempo, sistemas para procesarlos
- ▶ Operación de **convolución** ⇒ Operación lineal que **explota la estructura**
- ▶ **Respuesta en frecuencia** ⇒ Representación alternativa de señales con estructura
⇒ Permite encontrar una **manera rápida y fácil de calcular la convolución**
- ▶ Convolución en **imágenes** ⇒ Conceptualmente igual que la convolución en el tiempo

- ▶ La convolución es una operación lineal \Rightarrow Pero vimos que es mejor aprender algoritmos no lineales
 - \Rightarrow Redes neuronales convolucionales \Rightarrow Reemplazar la operación lineal por una convolución
 - \Rightarrow Ganar control sobre la representación \Rightarrow Múltiples features y bancos de filtros
- ▶ Pooling \Rightarrow Reducir la dimensionalidad en cada capa construyendo resúmenes
 - \Rightarrow Quedarse únicamente con resúmenes regionales \Rightarrow Invarianza local
- ▶ Algunas arquitecturas típicas usadas en la práctica